Modulo 6) Procesamiento y Análisis Bioinformático de datos de Secuenciación Masiva

El objetivo de este TP es familiarizarse con el procesamiento de datos de secuenciación masiva (NGS del inglés, Next Generation Sequencing). En particular en el TP realizaremos primero el proceso de “Mapeo” y “Llamado de variantes” y analizaremos ambos resultados, para luego “meter un poco más de mano” en el proceso de anotación.

Objetivo 61) Analizar el Mapeo para una serie de lecturas

Cuándo se realiza un experimento de secuenciación, lo que se obtienen son una serie de secuencias cortas denominadas lecturas (típicamente archivo fastQ). Uno de los objetivos bioinformáticos, cuando se analiza una muestra de un genoma cuya referencia ya es conocida (o sea ya se ha secuenciado el genoma tipo de la especie), como es el caso del genoma humano, el primer objetivo bioinformático consiste en “mapear” las lecturas sobre el genoma de referencia. Esto se realiza con el algoritmo de Burrow Wheelers y el resultado es un archivo de tipo SAM (o BAM en binario) con las lecturas correctamente mapeadas sobre el genoma de referencia.
El protocolo general de referencia para este proceso, y el posterior llamado de variantes, se basan en las buenas prácticas de GATK del Broad Institute y en este caso sólo realizaremos/analizaremos algunos de los pasos clave.

a) Análisis de Mapeo
Como el mapeo de las lecturas sobre el genoma de referencia es un proceso que lleva mucho tiempo (es el paso más costoso computacionalmente del proceso) en este caso ya lo hemos hecho y hemos obtenido como resultado los siguientes archivos

i) Archivos modulo6.sam/bam/bai son los denominados BAM/SAM que contienen las lecturas ya Mapeadas contra el genoma de referencia (bai es el índice del bam)
ii) Archivo Homo_sapiens_assembly38.chr1.fasta.gz que contiene el cromosoma 1 del genoma de referencia hg38 (y el fai es el índice).

El formato SAM (http://samtools.github.io/hts-specs/SAMv1.pdf) consiste en texto delimitado por tabs el cual tiene un encabezado (líneas que comienzan con @) con información general del secuenciamiento y del alineamiento, más una sección de alineamientos con 11 campos obligatorios y otros campos opcionales. Cada renglón de la sección de alineamientos corresponde a un segmento de lectura (read) de cada fragmento (template) introducido en el secuenciador. Ver Anexo 1 - Formato SAM para más información.
El formato BAM es la conversión binaria del SAM para manipulación computacional y reducción de espacio de disco.

Para manipular archivos SAM/BAM existen diferentes programas como SAMtools o PySAM, en y/o programando en bash/python el objetivo es obtener del SAM diferentes métricas que

caracterizan al proceso de mapeo y al experimento de NGS subyacente.

Ejercicio 61a) Obtenga a partir del archivo SAM las siguientes métricas

i) Profundidad para cada una de las posiciones del genoma de referencia (realice el gŕafico correspondiente)

ii) Profundidad promedio y desvío estándar

iii) Promedio y SD del largo de las lecturas mapeadas

iv) Cobertura (en %) del genoma target para un dado umbral de profundidad.

b) visualizarlo en IGV

Para visualizar las lecturas mapeadas/alineadas sobre la referencia usaremos el programa IGV. El IGV permite visualizar genomas (y sus anotaciones) y ver/analizar las lecturas mapeadas sobre el mismo. El primer paso para usar el IGV es bajarlo e instalarlo (para ello siga las instrucciones a continuación)

1) https://software.broadinstitute.org/software/igv/download -> descargamos la version linux
2) Lo descomprimimos y ejecutamos el archivo igv.sh
3) Una vez que se abra la pantalla, cargamos el genoma: “Genomes” -> “Load Genome From File” -> elegir genomic.fasta
4) Luego cargamos las anotaciones: “File” -> “Load from File” -> eleginos genomic.gb
5) Después cargamos el alineamiento: “File” -> “Load from File” -> eleginos modulo6.bam
6) Finalmente seleccionamos el área de interés “chr1:209,624,476-209,628,968”.

Si realizo bien el proceso debería ver en pantalla algo similar a lo siguiente:



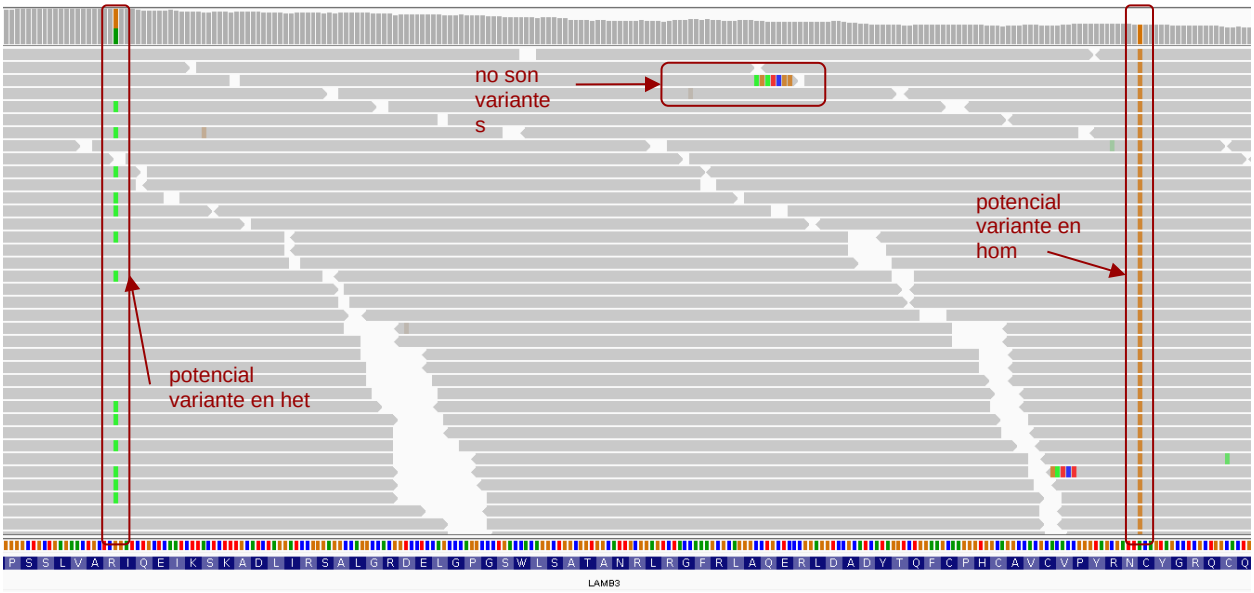
Ejercicio 61b) cargue el BAM en el IGV y trate de obtener con el mismo las métricas obtenidas en 61a, compare los resultados.

Objetivo 62) determinar las “potenciales” variantes

El objetivo ahora es determinar las variantes y escribir el archivo VCF correspondiente. Al igual que para el proceso de Mapeo, siguiendo las buenas prácticas de GATK nosotros ya hemos hecho el llamado de variantes obteniendo el archivo VCF correspondiente. (modulo6.vcf)

Ahora veremos si ud es capaz de obtener las mismas variantes que GATK. Para determinar las potenciales variantes lo que debemos hacer es determinar cuando alguna lectura posee una diferencia respecto del genoma de referencia. Para cada potencial variante lo que debemos guardar es el tipo de diferencia observada y su posición. Una vez marcadas las diferencias debemos usar la información de la profundidad (y usualmente de calidad de la lectura/base y sesgo de hebra) para quedarnos con aquellas que consideremos variantes reales y descartar aquellas diferencias que creemos se deben a un error en el secuenciador. Para nomenclar las variantes debemos guardar la base de la referencia (Ref: A) y la potencial variante (Alternativa o Alt:G). Muchas veces se usa la nomenclatura A>G.

Figura:



Ejercicio 62b): En base a los archivos SAM y FASTA y lo analizado en el ejercicio 61a, realice un programa que determine las variantes y las escriba en un archivo simil VCF. Para ello programe los siguientes módulos y luego combinelos
i) realice un programa que determine todas las potenciales variantes y para cada una guarde:
a) la profundidad de lecturas en “esa” posición del genoma de referencia.
b) la profundidad de la potencial variante observada

ii) realice un código que dados como parámetros umbrales de Profundidad de la posición y profundidad de la variante (para variantes homo y heterocigotas) filtre las diferencias y escriba el VCF resultante con las variantes.

Anexo 1 - Formato SAM

Formato SAM

El formato SAM (http://samtools.github.io/hts-specs/SAMv1.pdf) consiste en texto delimitado por tabs el cual tiene un encabezado (líneas que comienzan con @) con información general del secuenciamiento y del alineamiento, más una sección de alineamientos con 11 campos obligatorios y otros campos opcionales. Cada renglón de la sección de alineamientos corresponde a un segmento de lectura (read) de cada fragmento (template) introducido en el secuenciador.

Un extracto de un archivo SAM de ejemplo es el siguiente:

```
@SQ   SN:22 LN:51304566
HWI:993  163  22  727  60  101M  =  776  150  GGAACACACTC  CCCFFAE=FHH
HWI:993   83  22  776  60  101M  =  727  -150 CTTGTCGTACC  8<@>?9CACCC
```

En este ejemplo vemos sólo una línea de encabezado (que comienzan con @) , y a continuación dos líneas del listado de alineamientos. Para la primer línea de alineamiento vemos que:

- el nombre del template es `HWI:993`,
- que su flag es `163` (veremos su significado a continuación),
- el nombre de la secuencia de referencia es `22`,
- su posición de mapeo es `727`,
- su calidad de mapeo es `60`,
- su código CIGAR es `101M` (veremos su significado a continuación),
- la referencia del siguiente read en el template es la misma (`=`)
- y su posición es `776`,
- la longitud del template es de `150` bases,
- la secuencia de la lectura es `GGAACACACTC` (se muestran sólo 11 bases por legibilidad pero deberían ser 101),
- y por último la calidad es `CCCFFAE=FHH` (se muestran sólo 11 bases por legibilidad pero deberían ser 101).

Estos campos que componen la sección de alineamientos se resumen en la siguiente tabla:

Col	Campo	Tipo	Descricpción breve
1	QNAME	Cadena de caracteres	Identificador del template secuenciado
2	FLAG	Entero	Indicador binario (ver explicación)
3	RNAME	Cadena de caracteres	Nombre de la secuencia de referencia. Para el genoma humano es el número de cromosoma.
4	POS	Entero	Posición de Mapeo
5	MAPQ	Entero	Calidad de Mapeo
6	CIGAR	Cadena de caracteres	Código CIGAR (ver explicación)
7	RNEXT	Cadena de caracteres	Nombre de la secuencia de referencia del siguiente read en el template
8	PNEXT	Entero	Posición del siguiente read en el template
9	TLEN	Entero	Longitud observada del template
10	SEQ	Cadena de caracteres	Secuencia del segmento del template secuenciado
11	QUAL	Cadena de caracteres	ASCII of Phred-scaled base QUALity+33

FLAG

El campo FLAG se utiliza para indicar distintas condiciones que un read puede o no estar cumpliendo. Para representar estas condiciones en un sólo valor se utiliza un número entero (13, 3, 50 etc) cuya descomposición en potencias de dos permiten marcar el cumplimiento o no de cada condición (ver la siguiente tabla).

A modo de ejemplo, el número entero 13 se puede descomponer en potencias de dos como 1 + 4 + 8, lo que indica que se cumplen las condiciones: el *template* tiene muchos segmentos (1), el segmento no está mapeado (4) y el siguiente segmento del template no está mapeado (8).

¿Cómo descompondría el FLAG “163” y qué significa ese conjunto de condiciones? ¿Y el “83”?

Potencia de dos	Significado
1	template having multiple segments in sequencing
2	each segment properly aligned according to the aligner

4	segment unmapped
8	next segment in the template unmapped
16	SEQ being reverse complemented
32	SEQ of the next segment in the template being reversed
64	the first segment in the template
128	the last segment in the template
256	secondary alignment
512	not passing quality controls
1024	PCR or optical duplicate
2048	supplementary alignment

CIGAR

El campo CIGAR se utiliza para representar la lectura de manera sintética en base a la coincidencia de sus bases con la referencia. La codificación consiste en mostrar en orden las bases que coinciden, las no coincidencias, las deleciones, las inserciones, etc. En la siguiente tabla se detallan los posibles caracteres de la codificación.

Código	Descripción
M	alignment match (can be a sequence match or mismatch)
I	insertion to the reference
D	deletion from the reference
N	skipped region from the reference
S	soft clipping (clipped sequences present in SEQ)
H	hard clipping (clipped sequences NOT present in SEQ)
P	padding (silent deletion from padded reference)
=	sequence match
X	sequence mismatch

Por ejemplo, dado un read de longitud 101 bases, el CIGAR “101M” indica que todo el read alinea con la referencia.
Otro ejemplo un poco más complejo es “56M2D40M5I”. ¿Cómo interpreta este CIGAR? ¿Qué longitud tiene esta lectura?